INSTITUTO POLITÉCNICO NACIONAL

ESCUELA SUPERIOR DE CÓMPUTO

ESCOM

Trabajo Terminal

"PROTOTIPO DE UN SISTEMA WEB DE ANÁLISIS CONDUCTUAL ASISTIDO POR IA EN UN MODELO DE CONDUCTA DEPRESIVA EN RATA MEDIANTE NADO FORZADO"

2026-B066

Presentan

Frausto Robles Angel Ali

Rodriguez Verdin Sandoval Vanesa

Directores

Cordero Lopez Martha Rosa

Salas Ramírez Israel

Mayo 2026

Resumen

El presente proyecto propone el diseño, desarrollo y validación de un prototipo de sistema web asistido por inteligencia artificial orientado al análisis automatizado de la prueba de nado forzado (Forced Swim Test, FST) en ratas. El FST es un paradigma experimental estándar para la evaluación preclínica del potencial antidepresivo de moléculas en neurociencia conductual; sin embargo, su análisis actualmente depende de la observación manual cuadro a cuadro (frame a frame) de los videos, lo que implica un consumo elevado de tiempo y una variabilidad importante entre evaluadores.

El sistema propuesto integra un módulo de visión por computadora y aprendizaje supervisado capaz de clasificar cuadro a cuadro (frame a frame) las conductas de interés (nado activo, inmovilidad e intentos de escape) directamente sobre los videos proporcionados por el laboratorio colaborador, y una plataforma web que permite al investigador cargar los videos, ejecutar el análisis automático y obtener reportes cuantitativos por individuo y por sesión. Los resultados del sistema se compararán con anotaciones expertas para estimar su nivel de concordancia y la reducción de tiempo en el análisis.

El proyecto se desarrolla en colaboración con el grupo de investigación en neurociencia conductual de la Escuela Superior de Medicina y Homeopatía del IPN, que aporta el acervo de videos experimentales y el estándar de referencia del experto (gold standard) para la validación del sistema.

Palabras clave: visión por computadora, aprendizaje automático, prueba de nado forzado, farmacología conductual, sistema web, análisis conductual animal.

Índice general

Resumen I

1. Introducción 1

1.1. Antecedentes . . . 1
1.2. Planteamiento del problema . . . 2
1.3. Propuesta de solución . . . 3
1.4. Objetivo general . . . 4
1.4.1. Objetivos específicos . . . 4
1.5. Justificación . . . 5
1.6. Alcance del proyecto . . . 6
1.7. Metodología . . . 7

2. Estado del arte 9

2.1. Trabajos similares . . . 9
2.1.1. DSAAN: clasificación sin umbral en el FST . . . 9
2.1.2. Red 3D-RCNN para clasificación de tres conductas . . . 10
2.1.3. DLC como clasificador de conducta en el FST . . . 10
2.1.4. YOLO-Behaviour: detección + clasificación en dos etapas . . . 10
2.2. Herramientas comerciales de análisis conductual por video . . . 11
2.2.1. EthoVision XT . . . 11
2.2.2. ANY-maze . . . 11
2.3. Herramientas de código abierto para análisis del FST . . . 12
2.3.1. ezTrack . . . 12
2.3.2. DBscorer . . . 12
2.4. Técnicas de visión por computadora para seguimiento de animales . . . 12
2.4.1. Sustracción de fondo . . . 12

2.4.2. YOLO (You Only Look Once) 13
2.4.3. DeepLabCut 13
2.4.4. Trackers de correlación: CSRT y KCF 14
2.5. Modelos de clasificación supervisada aplicables al FST 14
2.5.1. Clasificadores clásicos sobre descriptores de movimiento 14
2.5.2. Redes convolucionales con transfer learning 15
2.5.3. Redes 3D para información temporal 15
2.6. Criterios de calidad para la evaluación del sistema 16
2.7. Limitaciones comunes y contexto del proyecto 16
2.8. Tabla comparativa 17

3. Marco teórico **18**
3.1. El modelo de nado forzado como paradigma preclínico 18
3.1.1. Depresión y modelos animales 18
3.1.2. La prueba de nado forzado (FST) 19
3.1.3. Conductas que se observan y cómo se interpretan 19
3.1.4. Protocolo del laboratorio colaborador 19
3.2. Redes neuronales y aprendizaje profundo 20
3.2.1. Idea general de una red neuronal 20
3.2.2. Redes convolucionales (CNN) 20
3.2.3. Transfer learning 20
3.2.4. ResNet 21
3.2.5. Clasificación de las tres conductas 21
3.3. Seguimiento de objetos en video 21
3.3.1. Trackers de correlación: CSRT y KCF 21
3.3.2. Estrategia de seguimiento en cascada 22
3.3.3. Métricas de evaluación 22
3.4. Arquitectura del sistema web 22
3.4.1. Arquitectura cliente-servidor y API REST 22
3.4.2. Procesamiento asíncrono con colas de tareas 22
3.4.3. Contenedorización con Docker 22
3.4.4. Persistencia de datos con PostgreSQL 22

4. Análisis **23**
4.1. Requerimientos 23

4.1.1. Requerimientos Funcionales (RF) 23
4.1.2. Requerimientos No Funcionales (RNF) 27
4.1.3. Reglas de negocio 29
4.2. Análisis de las herramientas a utilizar 31
4.2.1. Análisis de técnicas de detección de objetos y seguimiento 31
4.2.2. Análisis de arquitecturas de aprendizaje profundo para clasificación de conductas 32
4.2.3. Análisis de herramientas de desarrollo web, infraestructura y anotación 33
4.3. Análisis de riesgos 34
4.4. Análisis de factibilidad 37
4.4.1. Factibilidad tecnológica 37
4.4.2. Factibilidad operativa 38
4.4.3. Factibilidad económica 38
4.4.4. Factibilidad legal 39
4.5. Análisis de sostenibilidad 40
4.5.1. Sostenibilidad ambiental 40
4.5.2. Sostenibilidad social e institucional 40
4.5.3. Mantenibilidad del sistema 40

Índice de figuras

Índice de cuadros

1.1. Plan de trabajo por etapa académica. 8

2.1. Comparativa de herramientas y trabajos relacionados con el análisis del FST. 17

4.1. Requerimientos Funcionales (RF) [28], [29]. 24
4.2. Requerimientos No Funcionales (RNF). 27
4.3. Reglas de negocio. 30
4.4. Análisis de técnicas de detección de objetos y seguimiento. 31
4.5. Análisis de arquitecturas de aprendizaje profundo para clasificación de conductas. 32
4.6. Análisis de herramientas de desarrollo web, infraestructura y anotación. . 33
4.7. Matriz de riesgos del proyecto. 35
4.8. Estado de factibilidad por componente tecnológico. 37
4.9. Análisis de costos del proyecto. 38

Capítulo 1

Introducción

1.1. Antecedentes

El análisis del comportamiento animal con herramientas computacionales ha crecido notablemente en la última década. Lo que antes requería que un investigador se sentara horas frente a un video con cronómetro en mano, hoy puede delegarse a sistemas que procesan miles de cuadros por segundo. Esa transición no es trivial: implica que los resultados son más reproducibles, el tiempo de análisis se reduce y el sesgo del evaluador deja de ser una variable que contamina los datos [1], [2].

En el ámbito de la farmacología experimental, los roedores —especialmente ratas y ratones— son el modelo biológico más usado para el estudio de trastornos del estado de ánimo y el desarrollo de nuevos fármacos. Su fisiología y neuroanatomía tienen una correspondencia suficientemente alta con la humana, en particular en la organización del sistema nervioso central y las respuestas neuroendocrinas al estrés [1]. A eso se suman razones prácticas: son de manejo sencillo, tienen ciclos reproductivos cortos y el costo de mantenimiento es bajo comparado con otros modelos animales.

La depresión mayor afecta a más de 280 millones de personas en el mundo y es una de las principales causas de discapacidad según la OMS [3]. Para probar nuevos antidepresivos antes de llegar a ensayos clínicos en humanos, los investigadores usan modelos conductuales que reproducen algunos aspectos del trastorno. El más citado en neurociencia preclínica es la prueba de nado forzado (Forced Swim Test, FST), propuesta originalmente por Porsolt et al. en 1977 [4]. Desde el año 2000 hay más de 8,000 artículos que lo reportan como método de evaluación [2], lo que da una idea de su peso en la literatura.

En términos simples, el FST consiste en colocar a la rata en un cilindro con agua del

que no puede salir y registrar cómo responde. Al principio intenta escapar; con el tiempo empieza a flotar con movimientos mínimos. Esa conducta pasiva —llamada *desesperanza conductual* o *behavioral despair*— se asocia con la pérdida de motivación propia de la depresión [1]. Los fármacos antidepresivos reducen el tiempo de inmovilidad, y eso es precisamente lo que se mide [5], [6].

El uso de animales de laboratorio en México está regulado por la Norma Oficial Mexicana NOM-062-ZOO-1999 [7], que establece las especificaciones éticas, sanitarias y de bienestar animal aplicables a su cuidado y uso experimental. El laboratorio colaborador opera bajo esas disposiciones; el sistema desarrollado en este proyecto solo analiza los videos que resultan de los experimentos, sin intervenir en ningún procedimiento con los animales.

En los últimos años han surgido herramientas para automatizar el análisis de estos experimentos. EthoVision XT [8] y ANY-maze son las comerciales más usadas; ezTrack [9] y DBscorer [10] son las alternativas abiertas más específicas para el FST. Todas tienen limitaciones concretas: las comerciales son caras y no distinguen las tres conductas relevantes del FST; las abiertas tampoco clasifican nado, inmovilidad y escalamiento por separado, y ninguna tiene interfaz web. Los trabajos más recientes con aprendizaje profundo [2], [11] sí alcanzan esa clasificación de tres clases, pero no están disponibles como sistemas desplegables para laboratorios sin infraestructura de cómputo especializada.

El Laboratorio de Neurociencia Conductual de la ENMyH-IPN, dirigido por el Dr. Israel Salas Ramírez, realiza experimentos de FST de forma regular y tiene un acervo de videos que hoy se analizan a mano. De esa necesidad concreta nace este Trabajo Terminal.

1.2. Planteamiento del problema

El laboratorio colaborador corre experimentos de nado forzado periódicamente para evaluar el efecto de distintas moléculas en grupos de ratas. Cada experimento genera videos donde se graban cuatro animales al mismo tiempo desde una vista cenital, con teléfono o tableta, en dos sesiones: 20 minutos el primer día y 5 minutos el segundo día.

El análisis de esos videos se hace completamente a mano: un investigador reproduce la grabación y va anotando con un cronómetro cuándo cada rata nada, cuándo está inmóvil y cuándo intenta escalar. Los problemas de ese proceso son los siguientes:

- **Tiempo:** analizar un experimento completo puede llevar varias horas, según el número de animales y sesiones.

- **Variabilidad entre evaluadores:** dos personas pueden usar criterios distintos para decidir cuándo empieza o termina una conducta, lo que afecta la reproducibilidad de los resultados [1]. La norma ISO/IEC 25010:2023 [12] define la consistencia de resultados entre evaluadores como un atributo de calidad funcional (*correctness*); un sistema automatizado puede satisfacer ese atributo donde el análisis manual no puede garantizarlo.

- **Sin registro centralizado:** los resultados se guardan en archivos separados (hojas de cálculo, notas), sin forma fácil de comparar sesiones o grupos entre sí.

- **Análisis temporal limitado:** un desglose minuto a minuto de las conductas sería valioso para ver la dinámica del efecto farmacológico a lo largo de la sesión, pero hacerlo manualmente es prácticamente inviable.

Todo esto limita cuántos experimentos puede procesar el laboratorio y dificulta estandarizar sus resultados entre sesiones o con otros grupos.

1.3. Propuesta de solución

La propuesta es desarrollar un prototipo de sistema web que use inteligencia artificial para analizar automáticamente los videos del FST generados por el laboratorio. El desarrollo del sistema sigue el ciclo de vida de software descrito en la norma ISO/IEC/IEEE 12207:2017 [13], que estructura el proceso en fases de definición de requerimientos, diseño, implementación, verificación y mantenimiento. La adaptación concreta de ese ciclo al proyecto se describe en la sección de metodología.

El sistema tiene dos partes:

- **Pipeline de análisis de video:** recibe el video, identifica a cada rata dentro de su cilindro y clasifica cuadro a cuadro qué conducta realiza (nado, inmovilidad o escalamiento) con un modelo de aprendizaje supervisado. La salida es el tiempo total de cada conducta por animal y, de forma opcional, el desglose por minuto.

- **Plataforma web:** interfaz desde el navegador donde el investigador puede subir los videos, consultar el estado del análisis, revisar los resultados por animal y por sesión, y descargar reportes. Los datos se almacenan en una base de datos para facilitar la comparación entre experimentos.

El sistema asume que los videos tienen un formato y calidad mínimos para que el procesamiento sea viable: vista cenital con los cuatro cilindros visibles, contraste suficiente entre el animal y el fondo, y cámara estable. Los videos disponibles hasta ahora tienen variaciones de iluminación y contraste que pueden afectar el desempeño; durante el desarrollo se evaluará la robustez de los algoritmos ante esas condiciones y se documentarán los requisitos mínimos de calidad conforme a los criterios de *performance efficiency* de la ISO/IEC 25010:2023 [12].

Para validar el sistema, sus predicciones se compararán con los registros conductuales manuales del laboratorio (gold standard) usando el coeficiente kappa de Cohen y el error absoluto medio por animal.

1.4. Objetivo general

Diseñar, desarrollar y validar un prototipo de sistema web asistido por inteligencia artificial que automatice la detección y cuantificación de las conductas de la prueba de nado forzado en ratas —nado activo, inmovilidad e intentos de escape— con resultados comparables a la evaluación manual del laboratorio, cumpliendo los atributos de calidad funcional definidos en la norma ISO/IEC 25010:2023 [12].

1.4.1. Objetivos específicos

1. Revisar trabajos y herramientas existentes para el análisis automatizado del FST e identificar los enfoques de visión por computadora y clasificación supervisada más adecuados al problema.

2. Describir el protocolo experimental del FST que usa el laboratorio, incluyendo las conductas de interés y las características de los videos, a partir de entrevistas técnicas con el equipo del laboratorio y de los registros conductuales que éste proporcionará.

3. Diseñar la arquitectura del sistema conforme al proceso de diseño de software de la ISO/IEC/IEEE 12207:2017 [13], definiendo los módulos de carga de videos, pipeline de análisis, base de datos y visualización de resultados.

4. Implementar el módulo de análisis conductual con visión por computadora y un clasificador supervisado para las tres conductas del FST.

5. Validar el desempeño del sistema comparando sus predicciones contra los registros conductuales del laboratorio (gold standard), usando el coeficiente kappa de Cohen (κ) y el error absoluto medio como métricas principales.

6. Medir la reducción de tiempo de análisis frente al proceso manual y documentar bajo qué condiciones el sistema podría adaptarse a otros paradigmas conductuales.

1.5. Justificación

El análisis manual del FST tiene tres problemas concretos: toma mucho tiempo, depende del criterio del evaluador y no hay forma centralizada de guardar y comparar resultados. Un sistema automatizado resuelve los tres para el laboratorio colaborador.

Las herramientas comerciales disponibles (EthoVision XT, ANY-maze) no están diseñadas para el flujo de trabajo del laboratorio y tienen costos de licencia que no son accesibles en el contexto académico del IPN. Las de código abierto (ezTrack, DBscorer) no clasifican las tres conductas del FST ni tienen plataforma web. Los trabajos de investigación con aprendizaje profundo que sí clasifican las tres conductas [2], [11] no están disponibles como sistemas desplegables. Este prototipo cubre todo eso al mismo tiempo.

Desde el punto de vista de la calidad del software, el sistema se diseña para cumplir con los atributos de la norma ISO/IEC 25010:2023 [12] que son relevantes para este contexto: *functional correctness* (los resultados deben ser consistentes con las anotaciones del experto), *time behaviour* (el análisis no debe tardar más de lo que el laboratorio puede asumir en su flujo de trabajo) y *usability* (un investigador sin conocimientos de programación debe poder operar el sistema sin ayuda técnica). Esos atributos no son aspiracionales; son los criterios que se usarán para decidir si el prototipo cumple o no en la validación.

Desde el punto de vista académico, el proyecto aplica visión por computadora, aprendizaje automático y desarrollo web en un problema real con impacto en investigación biomédica. Eso encaja con el perfil de egreso de la ESCOM y con la línea de colaboración entre la ESCOM y la ENMyH-IPN.

1.6. Alcance del proyecto

Incluido en el alcance

- Análisis de videos del FST del laboratorio de la ENMyH-IPN, grabados desde arriba con cuatro cilindros simultáneos, bajo condiciones de grabación suficientes para que el procesamiento sea viable.
- Clasificación de tres conductas: nado activo, inmovilidad e intentos de escape. Si el sistema no logra distinguir con precisión suficiente nado y escalamiento, ambos se reportarán juntos como conducta activa.
- Métricas por animal y por sesión: tiempo total de cada conducta en los 5 minutos del día 2 y desglose por minuto como funcionalidad opcional.
- Comparación entre sesiones día 1 y día 2 para el mismo animal o grupo.
- Plataforma web con carga de videos, consulta de resultados y generación de reportes en PDF y CSV.
- Validación contra el gold standard del laboratorio con κ de Cohen y error absoluto medio.
- Documentación técnica conforme a los lineamientos de la CATT-ESCOM y al ciclo de vida de software de la ISO/IEC/IEEE 12207:2017 [13].

Fuera del alcance

- Análisis en tiempo real sobre video en vivo.
- Corrección automática de videos con mala iluminación, reflejos excesivos u otros problemas de calidad de grabación.
- Cualquier intervención en los experimentos con animales; eso lo hace el laboratorio bajo la NOM-062-ZOO-1999 [7].
- Despliegue institucional definitivo; el producto entregado es un prototipo funcional.
- Análisis de paradigmas conductuales distintos al FST en esta versión del sistema.

1.7. Metodología

El proyecto se desarrolla bajo una metodología ágil basada en Scrum, adaptada a un equipo de dos personas con entregas en dos etapas académicas (TT1 y TT2). La razón de elegir este enfoque es que el proyecto tiene componentes muy distintos entre sí —el módulo de video, el clasificador, la plataforma web, la base de datos— y diseñar todo desde el inicio, antes de probar el módulo de seguimiento, sería un riesgo innecesario. Scrum permite confirmar o ajustar decisiones de diseño al cierre de cada sprint, con base en evidencia de lo que funcionó.

Cada iteración termina con un entregable concreto revisable con los directores en sesiones quincenales. Las actividades se organizan según los procesos de implementación y verificación de la ISO/IEC/IEEE 12207:2017 [13]: criterios de aceptación definidos antes de codificar, revisión del producto al cierre de cada bloque, y registro de ajustes para el siguiente ciclo.

La Tabla 1.1 muestra la distribución de actividades por etapa académica y por integrante del equipo. Ángel Ali es responsable del sistema web y la infraestructura (backend, base de datos, frontend); Vanesa es responsable del pipeline de inteligencia artificial (preprocesamiento de video, clasificador de conducta, validación).

Las herramientas principales son: Python con Flask para el backend y el pipeline; OpenCV y TensorFlow/scikit-learn para procesamiento de video y clasificación; PostgreSQL para la base de datos; React.js para el frontend; BORIS para anotar el gold standard; y Git con Docker para control de versiones y despliegue.

Cuadro 1.1: Plan de trabajo por etapa académica.

Etapa	Bloque	Ángel Ali (sistema web)	Vanesa (pipeline IA)
TT1 Feb–Jun	Documentación caps. 1–2	Introducción, planteamiento, estado del arte y comparativa tecnológica.	Antecedentes FST, técnicas de visión por computadora y modelos ML/DL aplicables.
	Análisis (cap. 3)	RF/RNF, casos de uso, matriz de trazabilidad y criterios de aceptación por módulo.	Especificación de conductas, métricas, protocolo de anotación y plan de validación.
	Diseño (cap. 4)	Arquitectura del sistema, modelo E-R, API REST, diagramas UML y wireframes.	Pipeline de preprocesamiento, separación por sujeto, descriptores y arquitectura del clasificador.
	Entregable TT1	Protocolo registrado en CATT-ESCOM; documentación de caps. 1–4 aprobada por directores.	
TT2 Jul–Ene	Implementación base	Backend Flask + PostgreSQL, esquema de BD, API REST de sesiones y autenticación.	Baseline de sustracción de fondo, curación de videos y anotación del gold standard con BORIS.
	Implementación principal	Vistas React.js (carga, dashboard, reportes) e integración frontend-backend.	Clasificador entrenado (nado/inmovilidad/escape), ajuste de hiperparámetros y métricas por individuo.
	Integración, pruebas y robustez	Integración del módulo de IA al backend (worker/cola), pruebas unitarias y de sistema.	Pruebas con distintas condiciones de grabación, manejo de oclusiones y reporte de métricas finales.
	Entregable TT2	Sistema desplegado con Docker Compose; manuales técnico y de usuario; material de defensa.	

Capítulo 2

Estado del arte

Antes de definir cómo va a funcionar el sistema, revisamos qué herramientas y trabajos existen para el análisis automatizado del FST. La búsqueda se organizó en cuatro áreas: trabajos similares directamente relacionados con el problema, software comercial y de código abierto para análisis conductual por video, técnicas de visión por computadora y aprendizaje profundo aplicadas al seguimiento de animales, y enfoques de clasificación de conducta con modelos supervisados.

2.1. Trabajos similares

Antes de revisar las herramientas disponibles, vale la pena mirar qué grupos han intentado resolver el mismo problema o uno parecido, y qué resultados reportaron.

2.1.1. DSAAN: clasificación sin umbral en el FST

Meng et al. [11] propusieron DSAAN (Dual-Stream Attention-Augmented Network), un método con dos ramas paralelas que procesan apariencia y movimiento del animal por separado y luego combinan esa información para clasificar el estado cuadro a cuadro. La arquitectura procesa diferencias entre cuadros consecutivos (flujo de movimiento) en paralelo con la imagen original (apariencia), y un módulo de atención pondera la contribución de cada rama según el cuadro.

El resultado más relevante para este proyecto: con apenas 94 imágenes etiquetadas alcanzó un 88.7 % de precisión en la clasificación. Eso confirma que datasets pequeños —como el que se puede generar con los videos del laboratorio— son viables para este tipo de tarea si se elige la arquitectura correcta. El método fue validado en condiciones

controladas; los autores no reportan el comportamiento del sistema con variaciones de iluminación o reflejos del agua.

2.1.2. Red 3D-RCNN para clasificación de tres conductas

Della Valle et al. [2] entrenaron un modelo basado en redes residuales 3D (ResNet-3D) que procesa segmentos de video cortos para capturar el movimiento en el tiempo. A diferencia de la mayoría de los sistemas revisados, este distingue las tres conductas del FST: nado, inmovilidad y escalamiento. Los propios autores señalan que eso lo diferencia de trabajos anteriores, que solo discriminan entre inmovilidad y conductas activas en general.

La red 3D procesa volúmenes espacio-temporales —es decir, secuencias de cuadros como si fueran un volumen tridimensional— en lugar de cuadros individuales. Eso le permite capturar patrones de movimiento que no son visibles en un solo cuadro, como la dirección y velocidad del desplazamiento. La validación fue en condiciones controladas de laboratorio.

2.1.3. DLC como clasificador de conducta en el FST

Sturman et al. [14] mostraron que un clasificador entrenado sobre la representación esquelética producida por DeepLabCut puede eliminar la variabilidad entre evaluadores humanos en el FST. El enfoque consiste en extraer coordenadas de puntos corporales (nariz, patas, cola) en cada cuadro y usar esas coordenadas como descriptores para un clasificador supervisado. La ventaja es que el clasificador opera sobre una representación compacta del movimiento, no sobre la imagen cruda.

El costo es el esfuerzo de anotación: hay que marcar manualmente los puntos clave en decenas de cuadros antes de entrenar DeepLabCut, lo que implica un trabajo previo considerable.

2.1.4. YOLO-Behaviour: detección + clasificación en dos etapas

Chan et al. [15] presentaron un sistema que separa la detección del animal de la clasificación de su conducta. Primero YOLOv8 detecta y recorta la región del animal en cada cuadro; luego un clasificador independiente opera sobre ese recorte. Separar las dos tareas tiene una ventaja práctica: el clasificador trabaja sobre una imagen más limpia, sin el fondo ni los otros animales como distracción.

Ese enfoque de dos etapas —detección por YOLO seguida de clasificación sobre el recorte— es la arquitectura que adopta este proyecto.

2.2. Herramientas comerciales de análisis conductual por video

2.2.1. EthoVision XT

EthoVision XT (Noldus Information Technology) es el software más usado en laboratorios de neurociencia conductual para seguimiento automático de animales en video [8]. Detecta al animal en cada cuadro por sustracción de fondo y umbralización, y registra posición, velocidad y tiempo de inmovilidad. Tiene módulos para múltiples arenas simultáneas y exporta datos a formatos estadísticos estándar.

Para el FST, EthoVision detecta si el animal se mueve o no, pero no distingue entre nado, inmovilidad y escalamiento [2]. Esa limitación no es menor: sin distinguir las tres conductas, no es posible inferir sobre qué sistema neurotransmisor actúa el fármaco evaluado. Adicionalmente, requiere condiciones de iluminación controladas y su licencia tiene un costo que no es accesible en el contexto académico del IPN.

Desde el punto de vista de calidad del software, EthoVision cumple con criterios de *functional suitability* para seguimiento general, pero no satisface el subatributo de *functional completeness* definido en la ISO/IEC 25010:2023 [12] para el caso de uso específico del FST, al no cubrir la clasificación de las tres conductas de interés.

2.2.2. ANY-maze

ANY-maze (Stoelting Co.) tiene uso similar al de EthoVision. Su interfaz es más accesible y su curva de aprendizaje más corta, pero comparte las mismas limitaciones de fondo: requiere condiciones visuales controladas y no clasifica las subconductas del FST por separado.

2.3. Herramientas de código abierto para análisis del FST

2.3.1. ezTrack

ezTrack [9] es una herramienta de código abierto en Python diseñada para investigadores sin experiencia en programación. Corre sobre Jupyter Notebooks y cuantifica el movimiento comparando la diferencia absoluta entre cuadros consecutivos: los píxeles que cambian más de un umbral se consideran movimiento.

Es útil para experimentos simples donde solo importa si el animal se mueve o no. Tiene dos limitaciones concretas para este proyecto: hace clasificación binaria (móvil/inmóvil) y asume condiciones de grabación razonablemente controladas — iluminación uniforme, fondo constante, un solo animal por arena. No fue diseñada para vista cenital con varios cilindros al mismo tiempo.

2.3.2. DBscorer

DBscorer [10] es la herramienta de código abierto más específica para el FST y el test de suspensión de cola (TST). La desarrolló el Indian Institute of Science en MATLAB. Cuantifica la inmovilidad comparando el tamaño de la región del animal entre cuadros consecutivos: si el área varía poco, el animal se considera inmóvil.

Es un paso adelante frente al análisis manual, pero tiene limitaciones concretas para este proyecto: es sensible a cambios de iluminación y reflejos del agua, solo distingue móvil/inmóvil sin separar nado de escalamiento, está diseñada para un solo animal a la vez en perspectiva lateral, y no tiene interfaz web. La dependencia de MATLAB también implica una licencia de software que no siempre está disponible.

2.4. Técnicas de visión por computadora para seguimiento de animales

2.4.1. Sustracción de fondo

La sustracción de fondo es la técnica más básica para detectar objetos en movimiento en un video con cámara fija. El principio es simple: se estima una imagen de referencia del

fondo (el cilindro vacío) y en cada cuadro se calcula la diferencia con esa referencia. Los píxeles con diferencia mayor a un umbral se clasifican como primer plano (la rata).

El modelo de mezcla gaussiana (Gaussian Mixture Model, GMM) [16] es la versión adaptativa más usada: mantiene un modelo estadístico del fondo que se actualiza con cada cuadro, lo que le permite adaptarse a cambios lentos de iluminación. Para el caso de cámara fija que tiene el laboratorio, una alternativa más simple y predecible es calcular la mediana píxel a píxel de los primeros N cuadros. Usar la mediana en vez del promedio evita que una rata inmóvil al inicio del video contamine el modelo de fondo [17].

2.4.2. YOLO (You Only Look Once)

YOLO es un detector de objetos que aplica una sola red neuronal convolucional directamente sobre la imagen completa, produciendo en un solo paso las cajas delimitadoras (*bounding boxes*) y las probabilidades de clase de todos los objetos detectados [18]. A diferencia de detectores en dos etapas como Faster R-CNN, que primero propone regiones candidatas y luego las clasifica, YOLO trata la detección como un problema de regresión unificado sobre una cuadrícula.

La versión YOLOv8 (Ultralytics, 2023) reduce el tiempo de inferencia a 13.5 ms por cuadro en hardware de gama media y supera en precisión a EfficientDet y RetinaNet en benchmarks estándar. Para datasets pequeños, Stadler et al. [19] encontraron que con 100 a 350 imágenes etiquetadas se logra detección casi perfecta en fondos consistentes, lo cual es relevante dado el tamaño de dataset disponible en este proyecto. El modelo no generaliza bien cuando el fondo cambia mucho entre condiciones, lo que hay que considerar durante el entrenamiento.

2.4.3. DeepLabCut

DeepLabCut [20] es la herramienta estándar para seguimiento de pose en animales sin marcadores físicos. Usa redes convolucionales para detectar puntos anatómicos clave (nariz, patas, cola) definidos por el usuario en cada cuadro. La red se entrena con anotaciones manuales de un conjunto pequeño de cuadros representativos —100 a 200 imágenes suelen ser suficientes— y luego predice la posición de esos puntos en el video completo.

Su versión multianimales, maDLC [21], agrega un módulo de identificación que permite rastrear varios individuos al mismo tiempo, asignando correctamente los puntos de cada animal incluso cuando se cruzan.

La salida de DeepLabCut no es una caja delimitadora sino un conjunto de coordenadas precisas por punto corporal, lo que permite análisis biomecánicos: ángulos, trayectorias, velocidades segmentarias. Para el FST, Sturman et al. [14] demostraron que esas coordenadas son suficientes para entrenar un clasificador que elimina la variabilidad entre evaluadores. El precio es el esfuerzo de anotación previo.

2.4.4. Trackers de correlación: CSRT y KCF

Los trackers de correlación aprenden a reconocer cómo se ve el objeto que siguen y en cada cuadro buscan la región más parecida. Son distintos a los detectores: no necesitan saber qué es el objeto, solo cómo se veía en el cuadro anterior. CSRT (*Discriminative Correlation Filter with Channel and Spatial Reliability*) [22] es más preciso pero más lento; KCF (*Kernelized Correlation Filters*) [23] es más rápido pero menos robusto ante cambios bruscos de apariencia.

En el sistema propuesto, los trackers operan como respaldo cuando el detector falla: si YOLO no detecta a la rata en un cuadro, el tracker CSRT mantiene la estimación de posición hasta que el detector vuelve a encontrarla.

2.5. Modelos de clasificación supervisada aplicables al FST

Esta sección revisa los enfoques de machine learning y deep learning que son viables para clasificar las tres conductas del FST (nado, inmovilidad, escalamiento) dado el tamaño de dataset disponible y las condiciones de grabación del laboratorio.

2.5.1. Clasificadores clásicos sobre descriptores de movimiento

Los métodos clásicos de ML (SVM, Random Forest) toman como entrada descriptores numéricos del movimiento —área del contorno, velocidad del centroide, energía cinética, histogramas de flujo óptico— y producen una etiqueta de conducta. Su ventaja es que requieren pocos datos etiquetados y son interpretables. Su limitación es que los descriptores hay que definirlos a mano, lo que implica conocimiento previo sobre qué características discriminan mejor las conductas.

Para el FST, un descriptor útil es la relación entre el área de movimiento y la posición vertical del centroide: el escalamiento produce movimiento en la mitad superior del

cilindro mientras que el nado se distribuye en toda la superficie del agua. Esa diferencia es capturable con descriptores simples [1].

2.5.2. Redes convolucionales con transfer learning

Las CNN [24] son la arquitectura de referencia para clasificación de imágenes. Entrenar una CNN desde cero requiere cientos de miles de imágenes etiquetadas, lo cual no es viable con el dataset disponible. La solución es el *transfer learning* [25]: se toma una red preentrenada en ImageNet (más de un millón de imágenes de 1,000 clases) y se reemplaza solo la última capa de clasificación por una nueva con 3 salidas, una por conducta. Las capas anteriores ya saben detectar bordes, texturas y formas generales, y eso se aprovecha directamente.

ResNet-18 [26] es la arquitectura candidata principal para el clasificador de este proyecto. Tiene 18 capas con conexiones residuales (*skip connections*) que facilitan el entrenamiento en redes profundas al permitir que el gradiente fluya sin desvanecerse. Es ligera —ocupa menos de 50 MB— entrena rápido con datasets pequeños y tiene un buen balance entre precisión y velocidad de inferencia. Si ResNet-18 no alcanza la métrica objetivo ($\kappa > 0{,}80$), se prueba ResNet-50 como alternativa más profunda.

2.5.3. Redes 3D para información temporal

Las redes residuales 3D extienden las convoluciones al dominio temporal: en lugar de filtrar sobre una imagen 2D, filtran sobre un volumen de T cuadros consecutivos. Eso les permite capturar patrones de movimiento que no son visibles en un solo cuadro, como la dirección del nado o la frecuencia de los movimientos de escalamiento. Della Valle et al. [2] usan este enfoque y logran la clasificación de las tres conductas. El costo es computacional: las redes 3D requieren más memoria y tiempo de inferencia que las 2D, lo que puede ser una limitación en hardware sin GPU.

Para este proyecto, la primera opción es ResNet-18 en 2D sobre el recorte del animal (más simple, menor costo computacional). Las redes 3D quedan como alternativa si el clasificador 2D no alcanza la precisión necesaria.

2.6. Criterios de calidad para la evaluación del sistema

La selección de métricas de evaluación no es independiente del marco normativo. La norma ISO/IEC 25010:2023 [12] define los modelos de calidad para sistemas y software, y establece atributos medibles que permiten verificar si un sistema cumple sus objetivos. Para este proyecto, los atributos relevantes son:

- **Functional correctness:** los resultados del sistema deben ser consistentes con las anotaciones del laboratorio. Se mide con el coeficiente kappa de Cohen (κ), que cuantifica la concordancia entre dos evaluadores descontando el azar. El umbral objetivo es $\kappa > 0{,}80$, que corresponde a concordancia casi perfecta según la escala de Landis y Koch.
- **Time behaviour:** el tiempo de análisis de un video de 5 minutos debe ser aceptable para el flujo de trabajo del laboratorio. Se mide en minutos de procesamiento por minuto de video y se define el umbral concreto durante el Sprint 6 con el laboratorio.
- **Usability:** un investigador sin conocimientos de programación debe poder operar el sistema sin ayuda técnica. Se evalúa con una prueba de usabilidad con al menos un usuario real del laboratorio.

Además, el error absoluto medio (MAE) en segundos por animal y conducta completa los criterios de evaluación cuantitativos del clasificador.

2.7. Limitaciones comunes y contexto del proyecto

Todos los trabajos revisados se validaron bajo condiciones controladas: iluminación uniforme, fondo contrastante, sin reflejos problemáticos. Las herramientas basadas en umbralización (DBscorer, ezTrack) son especialmente sensibles a eso. Los métodos de aprendizaje profundo son más robustos en principio, pero dependen de que el conjunto de entrenamiento represente las condiciones reales de uso.

Los videos del laboratorio colaborador tienen características que complican las cosas: grabación con cámara de celular, variaciones de iluminación entre sesiones, y ratas de pelaje claro con poco contraste frente al cilindro. El sistema no garantiza robustez ante todas esas condiciones desde el inicio; evaluar qué tan bien funciona con los videos disponibles es parte del trabajo de desarrollo. La hipótesis es que los videos son suficientemente buenos para que el sistema funcione, pero eso se confirma o se ajusta durante las pruebas.

2.8. Tabla comparativa

La Tabla 2.1 resume los trabajos y herramientas revisados frente a los criterios más relevantes para el proyecto. La columna *Métricas reportadas* indica qué tan comparable es cada trabajo con los criterios de calidad de la ISO/IEC 25010:2023 [12] adoptados en este proyecto.

Cuadro 2.1: Comparativa de herramientas y trabajos relacionados con el análisis del FST.

Sistema	**Espec. FST**	**3 cond.**	**DL**	**Web**	**Abierto**	**Métricas reportadas**
EthoVision XT	Parc.	No	No	No	No	Posición, velocidad
ANY-maze	Parc.	No	No	No	No	Posición, velocidad
ezTrack	Parc.	No	No	No	Sí	% movimiento
DBscorer	Sí	No	No	No	Sí	Tiempo inmóvil
DSAAN	Sí	No	Sí	No	No	Precisión 88.7 %
3D-RCNN	Sí	Sí	Sí	No	No	F1 por clase
DeepLabCut+clf	Parc.	Parc.	Sí	No	Sí	κ vs. experto
YOLO-Behaviour	No	—	Sí	No	Sí	Precisión, recall
Propuesta	**Sí**	**Sí**	**Sí**	**Sí**	**Sí**	$\kappa > 0{,}80$, MAE, tiempo

Ningún sistema existente cubre los cinco criterios al mismo tiempo. Los comerciales no son abiertos y no clasifican las tres conductas. Los de código abierto no usan aprendizaje profundo ni tienen interfaz web. Los de aprendizaje profundo más recientes sí clasifican las tres conductas pero no tienen plataforma web y no reportan métricas de tiempo de análisis. El sistema propuesto busca cubrir los cinco criterios y documentar explícitamente los atributos de calidad de la ISO/IEC 25010:2023 [12], con la salvedad de que el desempeño real dependerá de la calidad de los videos del laboratorio.

Capítulo 3

Marco teórico

Este capítulo describe los conceptos teóricos en los que se apoya el sistema. Se organiza en tres bloques: el modelo biológico del FST y las conductas que interesa clasificar; los fundamentos de redes neuronales y aprendizaje profundo para la clasificación de conductas; y los elementos de arquitectura del sistema web. Las técnicas de procesamiento de video del módulo de seguimiento (sustracción de fondo, umbralización, contornos, línea de agua) se describen en el capítulo 6, dentro del desarrollo del módulo correspondiente.

3.1. El modelo de nado forzado como paradigma preclínico

3.1.1. Depresión y modelos animales

La depresión mayor afecta a más de 280 millones de personas y es una de las principales causas de discapacidad a nivel mundial [3]. Para probar nuevos tratamientos antes de llegar a humanos, los investigadores usan modelos animales que reproducen algunos aspectos del trastorno.

Para que un modelo animal sea válido debe cumplir tres criterios [5]: *validez de constructo* (los mecanismos biológicos involucrados deben parecerse a los del trastorno humano), *validez de cara* (los síntomas observables deben ser similares a los clínicos) y *validez predictiva* (el modelo debe responder a los fármacos que funcionan en pacientes).

3.1.2. La prueba de nado forzado (FST)

La prueba de nado forzado la propuso Porsolt et al. en 1977 [4]. Consiste en poner a la rata en un cilindro con agua del que no puede salir y registrar cómo se comporta. Al principio el animal intenta escapar, pero después de un rato empieza a quedarse flotando. Esa conducta pasiva se interpreta como *desesperanza conductual* (*behavioral despair*), que se asocia con la pérdida de motivación propia de la depresión [1].

La prueba funciona bien para evaluar antidepresivos porque la mayoría de los fármacos que son efectivos en humanos también reducen el tiempo de inmovilidad en ratas [6]. Desde el año 2000 hay más de 8,000 artículos que lo reportan [2].

3.1.3. Conductas que se observan y cómo se interpretan

En el FST se distinguen tres conductas [1], [6]. Son mutuamente excluyentes: en cada momento la rata solo puede estar haciendo una.

- **Inmovilidad**: el animal flota haciendo solo lo necesario para no hundirse. Es el indicador principal de desesperanza conductual.
- **Nado activo**: movimientos de paladas que desplazan al animal horizontalmente. Está relacionado con el sistema serotoninérgico; los antidepresivos tipo ISRS (como la fluoxetina) aumentan esta conducta.
- **Escalamiento**: movimientos rápidos hacia las paredes del cilindro, con las patas delanteras tocando o rompiendo la superficie del agua. Se asocia al sistema noradrenérgico; la desipramina, por ejemplo, lo incrementa.

Distinguir las tres conductas importa porque permite saber sobre qué sistema neurotransmisor actúa el fármaco evaluado. Un sistema que solo detecta si la rata se mueve o no pierde esa información.

3.1.4. Protocolo del laboratorio colaborador

En el laboratorio de la ENMyH las ratas se colocan individualmente en cilindros transparentes con agua. Hay dos sesiones: 20 minutos el día 1 (línea base) y 5 minutos el día 2 (después del tratamiento), con 24 horas de diferencia. Los videos se graban desde arriba con cámara de celular, capturando los cuatro cilindros al mismo tiempo. La iluminación y

el nivel del agua varían entre experimentos, y con ratas de pelaje claro el contraste contra el cilindro puede ser bajo. Estas condiciones son el caso de uso principal del sistema y determinarán en qué medida funcionan los algoritmos; los requisitos mínimos de calidad del video se definirán durante las pruebas de validación.

3.2. Redes neuronales y aprendizaje profundo

3.2.1. Idea general de una red neuronal

Una red neuronal aprende a partir de ejemplos. Está formada por capas de "neuronas" —funciones matemáticas simples— que se conectan entre sí. Cada neurona recibe valores, los pondera con unos pesos, los suma y aplica una función de activación. La más usada hoy en día es ReLU, que devuelve el valor si es positivo y cero si no.

Los pesos no se definen a mano: se aprenden durante el entrenamiento. El proceso es iterativo: se da al modelo un ejemplo con su respuesta correcta, se mide cuánto se equivocó, y se ajustan los pesos un poco para que la próxima vez lo haga mejor. Eso se hace con retropropagación y un optimizador como Adam [27], que es una versión mejorada del descenso por gradiente clásico.

3.2.2. Redes convolucionales (CNN)

Las CNN son redes diseñadas para trabajar con imágenes [24]. En vez de conectar cada píxel con cada neurona (lo que sería inmanejable), usan filtros pequeños que se deslizan por toda la imagen. El mismo filtro se aplica en cada posición, lo que reduce la cantidad de parámetros y permite detectar un patrón sin importar dónde esté.

Las capas iniciales aprenden bordes y cambios de color. Las más profundas combinan esas características para detectar formas más complejas. Al final, capas completamente conectadas hacen la clasificación.

3.2.3. Transfer learning

Entrenar una red desde cero requiere muchos datos etiquetados, normalmente cientos de miles de imágenes. Para este proyecto eso no es viable porque el laboratorio tiene un número limitado de videos.

La alternativa es el *transfer learning* [25]: se usa una red ya entrenada en otro dataset grande (ImageNet, con más de un millón de imágenes) y se adapta para la tarea nueva. En la práctica se reemplaza la última capa del modelo (que antes clasificaba 1,000 objetos) por una capa nueva con solo 3 salidas (una por conducta), y se re-entrena solo esa parte final con los videos del laboratorio. Las capas anteriores ya saben detectar bordes, texturas y formas generales, y eso se puede aprovechar directamente.

3.2.4. ResNet

ResNet [26] es una arquitectura CNN muy usada como punto de partida para transfer learning. La novedad que introdujo fueron conexiones directas que "saltan" una o más capas (*skip connections* o conexiones residuales). Eso facilita el entrenamiento cuando la red es muy profunda, porque el error puede fluir hacia atrás sin desvanecerse.

Para este proyecto se considera usar ResNet-18 o ResNet-50 como base del clasificador, según los resultados de las pruebas iniciales.

3.2.5. Clasificación de las tres conductas

El clasificador recibe el recorte de imagen alrededor de la rata (el bounding box), normalizado a un tamaño fijo. La capa de salida produce tres valores de probabilidad (uno por conducta) y se predice la de mayor valor. Para entrenar el modelo se necesitan cuadros de video etiquetados. Esas etiquetas las generan los autores del proyecto usando BORIS, tomando como referencia los registros conductuales (tiempos por conducta, por animal y por sesión) proporcionados por el laboratorio. Esos mismos registros constituyen el gold standard para la validación del sistema.

3.3. Seguimiento de objetos en video

3.3.1. Trackers de correlación: CSRT y KCF

Los trackers de correlación aprenden a reconocer cómo se ve el objeto que siguen y en cada cuadro buscan la región que más se le parece. CSRT [22] es más preciso pero más lento. KCF [23] es más rápido pero menos robusto ante cambios bruscos de apariencia. El sistema usa CSRT como primera opción y KCF como respaldo si CSRT no está disponible en la versión de OpenCV instalada.

3.3.2. Estrategia de seguimiento en cascada

El módulo implementa tres niveles de respaldo para que ningún cuadro quede sin detección. Primero intenta detectar a la rata por segmentación (sustracción de fondo). Si eso falla o el resultado no es consistente con el cuadro anterior, usa la predicción del tracker CSRT. Si ese también falla, congela la última posición conocida con una confianza que baja con el tiempo hasta un mínimo.

3.3.3. Métricas de evaluación

La métrica principal de validación es la kappa de Cohen (κ), que mide la concordancia entre dos evaluadores descontando lo que ocurriría por pura casualidad. Se busca alcanzar $\kappa > 0{,}80$, que corresponde a concordancia casi perfecta según Landis y Koch. También se calcula el error absoluto medio en segundos para tener una idea del error acumulado por animal.

3.4. Arquitectura del sistema web

3.4.1. Arquitectura cliente-servidor y API REST

3.4.2. Procesamiento asíncrono con colas de tareas

3.4.3. Contenedorización con Docker

3.4.4. Persistencia de datos con PostgreSQL

Capítulo 4

Análisis

En este capítulo se definen los requerimientos del sistema, las reglas que deben respetarse durante su operación, los riesgos que podrían afectar el desarrollo y la factibilidad del proyecto desde cuatro ángulos: tecnológico, operativo, económico y legal. Todo lo que se describe aquí es el punto de partida para el diseño e implementación del Capítulo 5.

4.1. Requerimientos

Para levantar los requerimientos se realizaron reuniones con el Dr. Israel Salas Ramírez, responsable del laboratorio de neurociencia conductual de la ENMyH-IPN, y se analizó paso a paso cómo trabaja el laboratorio con los videos del FST. De esas sesiones salieron dos tipos de requerimientos: los funcionales, que dicen qué debe hacer el sistema, y los no funcionales, que dicen bajo qué condiciones debe hacerlo [28], [29].

4.1.1. Requerimientos Funcionales (RF)

Los requerimientos funcionales están organizados por módulo con tres niveles de prioridad: **Alta** (sin esto el prototipo no sirve), **Media** (importante pero puede quedar para una iteración posterior) y **Baja** (sería bueno tenerlo pero no es urgente).

Cuadro 4.1: Requerimientos Funcionales (RF) [28], [29].

ID	Módulo	Descripción	Prioridad	Actor
RF-01	Autenticación	El sistema debe permitir iniciar sesión con correo electrónico y contraseña.	Alta	Investigador / Admin
RF-02	Autenticación	El sistema debe cerrar la sesión del usuario de forma segura, invalidando el token activo.	Alta	Investigador / Admin
RF-03	Autenticación	El sistema debe permitir recuperar la contraseña enviando un enlace al correo registrado.	Media	Investigador
RF-04	Autenticación	El sistema debe manejar dos roles con permisos distintos: Investigador y Administrador.	Alta	Admin
RF-05	Gestión de usuarios	El Administrador debe poder crear, modificar y desactivar cuentas de usuario.	Alta	Admin
RF-06	Gestión de usuarios	El Investigador debe poder actualizar su nombre, correo y contraseña desde su perfil.	Media	Investigador
RF-07	Gestión de usuarios	**PENDIENTE — PREGUNTAR AL DR. SALAS RAMÍREZ:** ¿los investigadores se registran solos (con confirmación por correo institucional) o solo el Administrador puede crear cuentas? Se define antes del Sprint 3.	Alta	Admin
RF-08	Carga de video	El sistema debe aceptar videos en formato MP4. AVI y MOV quedan como alternativa cuando esté disponible la conversión automática.	Alta	Investigador

ID	Módulo	Descripción	Prioridad	Actor
RF-09	Carga de video	El sistema debe permitir subir uno o dos videos por experimento: el del Día 1 (20 minutos) y el del Día 2 (5 minutos) del protocolo FST.	Alta	Investigador
RF-10	Carga de video	El sistema debe verificar que el archivo subido sea un video válido antes de procesarlo; si no lo es, debe rechazarlo con un mensaje claro.	Alta	Sistema
RF-11	Carga de video	Al subir el video, el investigador debe poder registrar los metadatos del experimento: nombre, fecha, tratamiento o condición, y número esperado de animales.	Alta	Investigador
RF-12	Análisis conductual	El análisis debe iniciarse automáticamente en cuanto termine la carga y se valide el video, sin que el investigador tenga que hacer nada más.	Alta	Sistema
RF-13	Análisis conductual	El sistema debe detectar solo, sin ayuda del usuario, la posición y número de cilindros que aparecen en el video.	Alta	Sistema
RF-14	Análisis conductual	El sistema debe clasificar cuadro a cuadro la conducta de cada animal: nado activo, inmovilidad o intentos de escape [1].	Alta	Sistema
RF-15	Análisis conductual	Mientras el análisis corre, el investigador debe ver el progreso en tiempo real con una barra o indicador de porcentaje.	Alta	Investigador
RF-16	Análisis conductual	Si el análisis falla, el sistema debe avisarle al usuario qué salió mal y darle la opción de descargar un reporte de diagnóstico en PDF.	Alta	Investigador

ID	Módulo	Descripción	Prioridad	Actor
RF-17	Resultados	El sistema debe mostrar el tiempo total en segundos de cada conducta, separado por animal y por sesión.	Alta	Investigador
RF-18	Resultados	El sistema debe desglosar la distribución de conductas por minuto para cada animal.	Media	Investigador
RF-19	Resultados	Cuando los dos videos del mismo experimento estén procesados, el sistema debe mostrar una comparación entre el Día 1 y el Día 2.	Alta	Investigador
RF-20	Resultados	El investigador debe poder descargar el reporte de resultados en PDF con un botón dedicado en la interfaz.	Alta	Investigador
RF-21	Resultados	El investigador debe poder descargar los datos de resultados en CSV con un botón dedicado en la interfaz.	Alta	Investigador
RF-22	Gestión de experimentos	El sistema debe mostrar la lista de experimentos del investigador activo con su estado (en proceso, completado, con error) y fecha de creación.	Alta	Investigador
RF-23	Gestión de experimentos	El investigador debe poder consultar los resultados de cualquier experimento que ya haya sido procesado.	Alta	Investigador
RF-24	Gestión de experimentos	El sistema debe borrar automáticamente los archivos de video 30 días después de que el análisis termine bien, notificándole al usuario con un aviso en la interfaz.	Media	Sistema
RF-25	Gestión de experimentos	Los resultados y reportes deben conservarse indefinidamente, aunque el video original ya haya sido borrado.	Alta	Sistema

ID	Módulo	Descripción	Prioridad	Actor
RF-26	Gestión de experimentos	El investigador debe poder borrar un experimento de su historial; la acción es permanente (incluye videos y resultados) y requiere confirmación explícita.	Media	Investigador
RF-27	Administración	El Administrador debe poder ver la lista de usuarios registrados y su actividad reciente.	Media	Admin
RF-28	Administración	El Administrador debe poder revisar el estado general del sistema: espacio en disco y tamaño de la cola de procesamiento.	Baja	Admin

4.1.2. Requerimientos No Funcionales (RNF)

Los requerimientos no funcionales dicen cómo debe comportarse el sistema más allá de las funciones que realiza: velocidad de respuesta, seguridad, compatibilidad y mantenibilidad.

Cuadro 4.2: Requerimientos No Funcionales (RNF).

ID	Categoría	Descripción	Métrica / Criterio de aceptación
RNF-01	Rendimiento	El análisis de un video de 5 minutos (Día 2 del FST, resolución típica de celular) debe terminar en un tiempo razonable para el flujo de trabajo del laboratorio. **PENDIENTE — PREGUNTAR AL DR. SALAS RAMÍREZ:** ¿cuánto tiempo de espera es aceptable? Se mide y define durante el Sprint 6.	Tiempo máximo a medir y documentar en el Sprint 6.

ID	Categoría	Descripción	Métrica / Criterio de aceptación
RNF-02	Rendimiento	La interfaz web debe responder a las acciones del usuario en menos de 3 segundos en condiciones normales de red.	Tiempo de respuesta $\leq$ 3 s en el 95 % de las solicitudes.
RNF-03	Disponibilidad	El sistema debe estar disponible en el horario de trabajo del laboratorio. No se requiere disponibilidad 24/7 para el prototipo.	95 % de disponibilidad de lunes a viernes, 8:00–20:00 h.
RNF-04	Seguridad	Solo los usuarios autenticados pueden acceder al sistema. Los videos y resultados de un usuario no deben ser visibles para otros sin autorización explícita.	Autenticación con JWT. Datos aislados por usuario en la base de datos.
RNF-05	Seguridad	Las contraseñas deben guardarse cifradas, nunca en texto plano.	Hash con sal usando bcrypt o equivalente.
RNF-06	Usabilidad	Un investigador sin experiencia en programación debe poder subir un video, esperar el análisis y descargar el reporte sin necesitar ayuda técnica.	Prueba con al menos un usuario del laboratorio durante el Sprint 6.
RNF-07	Compatibilidad	El sistema debe funcionar desde Chrome, Firefox y Edge actuales, sin instalar nada en el equipo del usuario.	Pruebas en los tres navegadores en sus versiones actuales.
RNF-08	Almacenamiento	Los videos se borran 30 días después de que el análisis termina bien. Los resultados y reportes se conservan indefinidamente.	Tarea programada (*cron job*) de limpieza que corre cada día.

ID	Categoría	Descripción	Métrica / Criterio de aceptación
RNF-09	Portabilidad	El sistema debe poder levantarse con Docker Compose en cualquier equipo que tenga Docker instalado, sin dependencias extra en el sistema anfitrión.	Despliegue documentado en al menos dos entornos distintos.
RNF-10	Escalabilidad	Debe ser posible agregar soporte para otros paradigmas conductuales reconfigurando solo el módulo de clasificación, sin tocar la plataforma web.	Diseño modular verificado en la revisión de arquitectura del Sprint 2.
RNF-11	Mantenibilidad	El código debe estar documentado y separado en módulos independientes (backend, pipeline de IA, frontend), siguiendo PEP 8 en Python y ESLint en JavaScript.	Revisión de calidad de código en cada cierre de sprint.
RNF-12	Concurrencia	**PENDIENTE — PREGUNTAR AL DR. SALAS RAMÍREZ:** ¿cuántos usuarios y análisis simultáneos necesita soportar el sistema, y con qué infraestructura cuenta el laboratorio? Se define antes del Sprint 6 (pruebas de carga).	Pendiente. Se documenta antes del Sprint 6.

4.1.3. Reglas de negocio

Las reglas de negocio son los límites que el sistema siempre debe respetar, independientemente de cómo esté implementado. Algunas vienen del protocolo experimental del FST, otras de buenas prácticas de ingeniería de software y otras del contexto del laboratorio [28]. Están escritas de forma que cualquiera pueda verificar si el sistema las cumple.

Cuadro 4.3: Reglas de negocio.

ID	Regla	Justificación
RN-01	Un video pertenece a exactamente un experimento. No se puede reutilizar un video ya subido para asociarlo a un experimento distinto.	Garantiza que los resultados siempre sean trazables a su origen.
RN-02	Un experimento tiene como máximo dos videos: uno del Día 1 (20 minutos) y uno del Día 2 (5 minutos).	Así funciona el protocolo FST del laboratorio colaborador [5].
RN-03	La comparación entre Día 1 y Día 2 solo se genera si los dos videos del mismo experimento ya fueron procesados exitosamente.	No tiene sentido comparar si falta la mitad de los datos.
RN-04	El análisis lo inicia el sistema solo, cuando termina la carga. El investigador no puede iniciarlo, pausarlo ni reiniciarlo a mano.	Evita que la cola de procesamiento quede en estados inconsistentes.
RN-05	Los videos se borran automáticamente 30 días después de que el análisis termina. La acción es irreversible y el usuario recibe un aviso en la interfaz antes de que ocurra.	Controla el uso del almacenamiento y protege los datos del laboratorio.
RN-06	Los resultados y reportes (PDF y CSV) se conservan aunque el video original ya haya sido borrado.	Los datos de investigación tienen valor a largo plazo.
RN-07	En cada cuadro del video, a cada animal se le asigna exactamente una conducta: nado activo, inmovilidad o escalamiento. No puede tener dos al mismo tiempo.	El FST define estas conductas como mutuamente excluyentes [1], [6].
RN-08	Cada investigador solo puede ver sus propios experimentos y resultados. El Administrador puede ver todo.	Control de acceso básico para proteger la confidencialidad de los datos.

ID	Regla	Justificación
RN-09	Borrar un experimento es permanente: se eliminan el video, los resultados y los reportes. El sistema pide confirmación explícita antes de ejecutarlo.	Previene borrados accidentales de datos de investigación.
RN-10	Antes de procesar cualquier video, el sistema verifica que el archivo tenga formato válido. Si no lo tiene, lo rechaza sin gastar recursos de cómputo.	No tiene sentido encolar un archivo que el pipeline no puede procesar.

4.2. Análisis de las herramientas a utilizar

La elección del *stack* tecnológico no fue arbitraria. Para cada componente del sistema se evaluaron las opciones disponibles según su madurez, compatibilidad con el resto de las herramientas, disponibilidad de documentación y experiencia previa del equipo. Las herramientas se agrupan en cuatro áreas.

4.2.1. Análisis de técnicas de detección de objetos y seguimiento

Cuadro 4.4: Análisis de técnicas de detección de objetos y seguimiento.

Herramienta	Características principales	Por qué se eligió
OpenCV 4.x [30]	Biblioteca estándar para procesamiento de imágenes y video. Incluye sustracción de fondo, umbralización, morfología, contornos y los trackers CSRT y KCF.	Es la herramienta de referencia para este tipo de trabajo en Python y es compatible con YOLOv8 y TensorFlow sin configuración extra.
Ultralytics YOLOv8 [18]	Detector de objetos estado del arte. Funciona bien con datasets pequeños ($\geq$50 imágenes) y produce *bounding boxes* precisos en fondos consistentes.	Ya se usó para entrenar el detector de rata (`weights/rat.pt`), así que la viabilidad técnica está confirmada.

Herramienta	**Características principales**	**Por qué se eligió**
Sustracción de fondo por mediana [17]	El fondo se estima como la mediana píxel a píxel de los primeros N cuadros. Funciona bien aunque la rata esté inmóvil al inicio del video.	Más simple y predecible que el modelo de mezcla gaussiana [16] para el caso de cámara fija. Ya está implementado en `tracker.py`.
Tracker CSRT [22]	Tracker de correlación que mantiene el seguimiento entre cuadros. Es más preciso que KCF aunque un poco más lento.	Primera opción para el seguimiento. Si CSRT no está disponible en la versión de OpenCV instalada, se usa KCF [23] como respaldo.

4.2.2. Análisis de arquitecturas de aprendizaje profundo para clasificación de conductas

Cuadro 4.5: Análisis de arquitecturas de aprendizaje profundo para clasificación de conductas.

Herramienta / Arquitectura	**Características principales**	**Por qué se eligió**
ResNet-18 [26]	Red con 18 capas y conexiones residuales, preentrenada en ImageNet. Es ligera y entrena rápido con datasets pequeños usando *transfer learning* [25].	Es la primera opción para el clasificador de conducta que opera sobre los recortes de cada rata.
ResNet-50 [26]	Versión más profunda (50 capas). Tiene más capacidad que ResNet-18 pero también cuesta más en tiempo de entrenamiento e inferencia.	Se usará si ResNet-18 no alcanza $\kappa > 0{,}80$.

Herramienta / Arquitectura	**Características principales**	**Por qué se eligió**
TensorFlow 2.x / Keras [31]	Framework de aprendizaje profundo con una API de alto nivel que simplifica el *fine-tuning* de modelos preentrenados.	Ya se usa en el proyecto y es compatible con Docker para el despliegue.
scikit-learn [32]	Biblioteca de ML para preprocesamiento, métricas y validación cruzada.	Se necesita para calcular el coeficiente κ de Cohen y las métricas de clasificación por clase.

4.2.3. Análisis de herramientas de desarrollo web, infraestructura y anotación

Cuadro 4.6: Análisis de herramientas de desarrollo web, infraestructura y anotación.

Herramienta	**Características principales**	**Por qué se eligió**
Flask (Python) [33]	Microframework ligero para construir APIs REST. Tiene extensiones para autenticación (Flask-JWT-Extended), ORM (SQLAlchemy) y tareas asíncronas.	Es suficiente para el tamaño del prototipo y permite integrar el pipeline de IA sin un framework más pesado.
React.js + Vite	Framework frontend basado en componentes. Vite reduce los tiempos de compilación durante el desarrollo.	Es la opción más adecuada para construir la barra de progreso en tiempo real y el resto de la interfaz reactiva que necesita el sistema.

Herramienta	**Características principales**	**Por qué se eligió**
PostgreSQL	Base de datos relacional con soporte para transacciones ACID y tipos de datos avanzados. Es de código abierto.	Cubre los patrones de acceso del sistema y se integra sin problema con SQLAlchemy.
Docker + Docker Compose [34]	Permite empaquetar todos los servicios del sistema (backend, frontend, base de datos, worker) en contenedores y levantarlos juntos con un solo comando.	El laboratorio no tiene que instalar nada más allá de Docker para correr el sistema.
BORIS [35]	Software de código abierto para anotar conductas en video cuadro a cuadro. Exporta en varios formatos compatibles con análisis estadístico.	Es la herramienta con la que los autores del proyecto anotarán los cuadros de video tomando como referencia los registros conductuales proporcionados por el laboratorio, generando así el conjunto de entrenamiento y el *gold standard* para la validación.

4.3. Análisis de riesgos

Identificar los riesgos desde el principio no significa que vayan a ocurrir, pero permite tener un plan antes de que sea urgente. Cada riesgo tiene una probabilidad estimada, un nivel de impacto y una acción concreta para reducir el daño.

Cuadro 4.7: Matriz de riesgos del proyecto.

ID	Descripción	Prob.	Impacto	Nivel	Mitigación
R-01	Los videos del laboratorio tienen reflejos, variaciones de iluminación o ratas de pelaje muy claro, y eso hace que el pipeline no funcione bien.	Alta	Alto	Alto	Definir con el laboratorio los requisitos mínimos de calidad de video y ajustar los parámetros de preprocesamiento durante las primeras pruebas.
R-02	El dataset disponible (63 imágenes) no alcanza para entrenar un clasificador de conducta que llegue a $\kappa > 0{,}80$.	Alta	Alto	Alto	Ampliar el dataset anotando más *frames* con BORIS. Usar *data augmentation*. Si el escalamiento sigue siendo difícil de distinguir, reportarlo junto con el nado activo como "conducta activa".
R-03	El laboratorio no puede proporcionar los registros conductuales en el tiempo necesario para el entrenamiento y validación del clasificador.	Media	Alto	Medio	Acordar un calendario de entrega de registros desde el inicio del TT2 y preparar los materiales con anticipación para aprovechar cada sesión.
R-04	Procesar un video de 5 minutos tarda más de lo que el laboratorio puede esperar en su flujo normal de trabajo.	Media	Medio	Medio	Medir dónde se van los tiempos en el pipeline y ver si reducir la resolución de análisis o agregar GPU resuelve el problema.

ID	Descripción	Prob.	Impacto	Nivel	Mitigación
R-05	Integrar el módulo de IA (Python / OpenCV) con la plataforma web (Flask / React) a través de la cola asíncrona resulta más complicado de lo esperado.	Media	Medio	Medio	Definir los contratos de API desde el Sprint 2 y hacer una prueba de integración de extremo a extremo en el Sprint 3, antes de agregar más funcionalidad.
R-06	El equipo de despliegue se queda sin espacio en disco por los videos acumulados durante los 30 días de retención.	Baja	Medio	Bajo	Documentar cuánto ocupa cada experimento. Poner alertas de disco. La eliminación automática a 30 días evita que el problema crezca indefinidamente.
R-07	El laboratorio pide cambios en los requerimientos a mitad del desarrollo: una conducta nueva o condiciones de grabación distintas.	Baja	Alto	Medio	Diseñar el clasificador de forma modular para que sea fácil agregar nuevas clases. Gestionar cualquier cambio dentro del proceso de revisión de sprint.
R-08	Desde la vista superior del video, el escalamiento y el nado activo se ven tan parecido que el modelo no puede distinguirlos con suficiente precisión.	Alta	Medio	Medio	Esto ya está contemplado en el alcance del Capítulo 1: si no se alcanza la precisión suficiente, ambas conductas se reportan juntas como “conducta activa”.

4.4. Análisis de factibilidad

El análisis de factibilidad responde a una pregunta concreta: ¿es posible hacer este sistema? Se revisa desde cuatro ángulos para asegurarse de que no hay ningún obstáculo que lo haga inviable.

4.4.1. Factibilidad tecnológica

El proyecto es tecnológicamente viable. Todas las herramientas del *stack* son de código abierto, están bien documentadas y el equipo tiene experiencia con la mayoría desde cursos de la carrera en la ESCOM.

Lo más importante es que el modelo de detección de rata ya funciona: se entrenó YOLOv8 con el dataset disponible, los pesos están en `weights/rat.pt` y las métricas de entrenamiento quedaron en `runs/detect/train/`. Eso confirma que al menos la detección es viable con los videos del laboratorio. Para el clasificador de conducta hay que anotar más *frames* con BORIS, pero la arquitectura (ResNet-18 con *transfer learning*) es aplicable al problema con el tamaño de dataset que se puede generar.

Si el laboratorio no tiene GPU disponible para el entrenamiento, Google Colab resuelve eso de forma gratuita con hasta 12 horas de GPU por sesión.

Cuadro 4.8: Estado de factibilidad por componente tecnológico.

Componente	**Estado**
Detección de rata (YOLOv8)	Factible — modelo entrenado con métricas disponibles en `runs/detect/train/`.
Clasificador de conducta (ResNet)	Factible — requiere ampliar el dataset de anotaciones con BORIS.
Pipeline de seguimiento (OpenCV)	Factible — implementado en `tracker.py` y documentado en el Capítulo 6.
Backend Flask + PostgreSQL	Factible — estructura base en `backend/app/`.
Frontend React	Factible — esqueleto en `frontend/src/`; faltan las vistas.
Despliegue Docker Compose	Factible — `docker-compose.yml` ya está en el repositorio.

Componente	Estado
Entrenamiento con GPU	Factible — Google Colab como opción gratuita si no hay GPU local.

4.4.2. Factibilidad operativa

El sistema no cambia el protocolo del laboratorio. El investigador sigue grabando los videos igual que siempre; lo único diferente es que en vez de analizarlos a mano, los sube a la plataforma y espera el resultado.

Al ser una aplicación web, no hay nada que instalar en el equipo del usuario. Eso baja la barrera de adopción, especialmente en un laboratorio donde no todos tienen conocimientos técnicos. La prueba de usabilidad del Sprint 6 confirmará si esto funciona con al menos un usuario real del laboratorio.

Los reportes salen en PDF y CSV, que son los formatos que ya usa el laboratorio para sus análisis estadísticos en hojas de cálculo, R o MATLAB, así que encajan en el flujo de trabajo sin cambios adicionales.

4.4.3. Factibilidad económica

No hay costo de licencias porque todas las herramientas son de código abierto. El desarrollo lo hace el equipo del TT sin costo adicional, y para la infraestructura de despliegue se usa el equipo del laboratorio o las computadoras del equipo de desarrollo.

Cuadro 4.9: Análisis de costos del proyecto.

Concepto	Costo estimado
Licencias de software (Python, Flask, React, PostgreSQL, Docker, YOLOv8, OpenCV, BORIS)	$0.00 — todas son de código abierto con licencias compatibles con uso académico.
Entrenamiento del modelo (GPU)	$0.00 — Google Colab gratuito con hasta 12 h de GPU por sesión.
Infraestructura de despliegue	Sin costo adicional — equipo del laboratorio o computadora del equipo de TT.

Concepto	**Costo estimado**
Almacenamiento de videos (estimado)	∼500 MB por experimento de 5 min en MP4. La eliminación automática a 30 días evita que el disco crezca indefinidamente.
Costo total de herramientas y software	**$0.00**

El proyecto no necesita financiamiento externo y no hay costos que dependan de aprobaciones institucionales para empezar.

4.4.4. Factibilidad legal

Todas las herramientas del proyecto usan licencias de código abierto que permiten el uso académico sin restricciones:

- **Python:** licencia PSF — uso libre.
- **Flask:** licencia BSD — uso libre.
- **React:** licencia MIT — uso libre.
- **PostgreSQL:** licencia PostgreSQL (similar a BSD) — uso libre.
- **Docker:** licencia Apache 2.0 — uso libre.
- **Ultralytics YOLOv8:** licencia AGPL-3.0 para uso no comercial — compatible con el uso académico de este proyecto.
- **OpenCV:** licencia Apache 2.0 — uso libre.
- **BORIS:** licencia GNU GPL v3 — uso libre para investigación [35].

Los videos que usa el sistema son propiedad del grupo de investigación de la ENMyH-IPN y su uso está respaldado por la colaboración formal entre los directores del TT y el laboratorio. No se publican ni se comparten fuera del proyecto.

El equipo de desarrollo no interviene en ningún experimento con animales. Eso lo hace el laboratorio, que ya tiene los permisos institucionales y éticos necesarios. El sistema solo analiza las grabaciones que resultan de esos experimentos.

4.5. Análisis de sostenibilidad

Más allá de que el proyecto funcione técnicamente, vale la pena preguntarse qué pasa con él a largo plazo.

4.5.1. Sostenibilidad ambiental

Reducir el análisis manual significa que los investigadores no tienen que ir al laboratorio solo para sentarse a cronometrar videos. Al ser web, el sistema puede usarse desde cualquier lugar, lo que elimina ese desplazamiento para esas tareas.

El costo energético de procesar video en una computadora es marginal comparado con las horas de trabajo que reemplaza. La política de borrar los videos a los 30 días evita que el disco crezca sin control.

4.5.2. Sostenibilidad social e institucional

El sistema está hecho para el laboratorio de la ENMyH, pero su diseño modular permite adaptarlo a otros paradigmas conductuales (laberinto en cruz elevada, campo abierto, etc.) reconfigurando solo el módulo de clasificación. Eso abre la puerta a que otros grupos del IPN puedan usarlo sin tener que desarrollarlo desde cero.

Al estandarizar el análisis y reducir la variabilidad humana, el sistema también contribuye a que los resultados del laboratorio sean más reproducibles, lo que tiene impacto directo en la calidad de la investigación [1].

4.5.3. Mantenibilidad del sistema

El sistema se entrega como prototipo funcional. Para mantenerlo hace falta alguien que sepa lo básico de Python y Docker, sin necesidad de ser experto. La documentación técnica de este documento y el `README` del repositorio están pensados para que cualquiera que retome el proyecto pueda entenderlo sin depender del equipo original.

Las herramientas principales (YOLOv8, Flask, React, PostgreSQL) tienen desarrollo activo y comunidades grandes, así que no hay riesgo de que queden obsoletas en el horizonte de tiempo de este prototipo.

Bibliografía

[1] A. Armario, «The forced swim test: Historical, conceptual and methodological considerations and its relationship with individual behavioral traits,» *Neuroscience and Biobehavioral Reviews*, vol. 128, págs. 74-86, 2021. DOI: 10.1016/j.neubiorev.2021.06.014.

[2] A. Della Valle, S. De Carlo, G. Sonsini, M. Ubaldi y R. Ciccocioppo, «Machine learning-based model for behavioural analysis in rodents applied to the forced swim test,» *Scientific Reports*, vol. 15, 2025. DOI: 10.1038/s41598-025-05712-8.

[3] World Health Organization, *Trastorno depresivo (depresión)*, 2025. dirección: https://www.who.int/es/news-room/fact-sheets/detail/depression (visitado 01-02-2026).

[4] R. D. Porsolt, A. Bertin y M. Jalfre, «Behavioral despair in mice: A primary screening test for antidepressants,» *Archives Internationales de Pharmacodynamie et de Therapie*, vol. 229, n.º 2, págs. 327-336, 1977.

[5] D. A. Slattery y J. F. Cryan, «Using the rat forced swim test to assess antidepressant-like activity in rodents,» *Nature Protocols*, vol. 7, n.º 6, págs. 1009-1014, 2012. DOI: 10.1038/nprot.2012.044.

[6] J. F. Cryan, C. Mombereau y A. Vassout, «The tail suspension test as a model for assessing antidepressant activity,» *Neuroscience and Biobehavioral Reviews*, vol. 29, págs. 571-625, 2005. DOI: 10.1016/j.neubiorev.2005.03.009.

[7] Secretaría de Agricultura, Ganadería, Desarrollo Rural, Pesca y Alimentación, «Norma Oficial Mexicana NOM-062-ZOO-1999: Especificaciones técnicas para la producción, cuidado y uso de los animales de laboratorio,» Diario Oficial de la Federación, inf. téc., 2001. dirección: https://www.gob.mx/cms/uploads/attachment/file/203594/NOM-062-ZOO-1999_220801.pdf (visitado 01-02-2026).

[8] Noldus Information Technology, *EthoVision XT | Video tracking software*, n.d. dirección: https://noldus.com/ethovision-xt (visitado 01-02-2026).

[9] Z. T. Pennington, Z. Dong, Y. Feng et al., «ezTrack: An open-source video analysis pipeline for the investigation of animal behavior,» *Scientific Reports*, vol. 9, n.º 1, pág. 19 979, 2019. DOI: 10.1038/s41598-019-56408-9.

[10] A. Nandi, G. Virmani, A. Barve y S. Marathe, «DBscorer: An Open-Source Software for Automated Accurate Analysis of Rodent Behavior in Forced Swim Test and Tail Suspension Test,» *eNeuro*, vol. 8, n.º 6, 2021. DOI: 10.1523/ENEURO.0305-21.2021.

[11] X. Meng, Y. Xia, M. Liu et al., «A deep-learning-based threshold-free method for automated analysis of rodent behavior in the forced swim test and tail suspension test,» *Journal of Neuroscience Methods*, vol. 409, pág. 110 212, 2024. DOI: 10.1016/j.jneumeth.2024.110212.

[12] ISO/IEC, «ISO/IEC 25010:2023 — Systems and software engineering — Systems and software quality models,» International Organization for Standardization, inf. téc., 2023.

[13] ISO/IEC/IEEE, «ISO/IEC/IEEE 12207:2017 — Systems and software engineering — Software life cycle processes,» International Organization for Standardization, inf. téc., 2017.

[14] O. Sturman, L. von Ziegler, C. Schlaeppi et al., «Deep learning-based behavioral analysis enables high precision rodent tracking and is capable of outperforming commercial solutions,» *Neuropsychopharmacology*, vol. 45, págs. 1137-1144, 2020. DOI: 10.1038/s41386-020-0776-y.

[15] Y.-H. Chan, J. A. Klarevas-Irby y D. R. Farine, «YOLO-Behaviour: A simple, flexible framework to automatically quantify animal behaviours from videos,» *Methods in Ecology and Evolution*, 2025. DOI: 10.1111/2041-210X.14502.

[16] Z. Zivkovic, «Improved adaptive Gaussian mixture model for background subtraction,» en *Proceedings of the 17th International Conference on Pattern Recognition (ICPR)*, vol. 2, 2004, págs. 28-31. DOI: 10.1109/ICPR.2004.1333992.

[17] M. Piccardi, «Background subtraction techniques: a review,» en *Proceedings of the IEEE International Conference on Systems, Man and Cybernetics*, 2004, págs. 3099-3104. DOI: 10.1109/ICSMC.2004.1400815.

[18] G. Jocher, A. Chaurasia y J. Qiu, *Ultralytics YOLO (Version 8.0.0)*, 2023. dirección: https://github.com/ultralytics/ultralytics (visitado 01-02-2026).

[19] J. H. Stadler, H. Luckow y C. Goeke, «Automatic object detection for behavioural research using YOLOv8,» *Behavior Research Methods*, vol. 56, n.º 7, págs. 7307-7330, 2024. DOI: 10.3758/s13428-024-02420-5.

[20] A. Mathis, P. Mamidanna, K. M. Cury et al., «DeepLabCut: Markerless pose estimation of user-defined body parts with deep learning,» *Nature Neuroscience*, vol. 21, n.º 9, págs. 1281-1289, 2018. DOI: 10.1038/s41593-018-0209-y.

[21] J. Lauer, M. Zhou, S. Ye et al., «Multi-animal pose estimation, identification and tracking with DeepLabCut,» *Nature Methods*, vol. 19, n.º 4, págs. 496-504, 2022. DOI: 10.1038/s41592-022-01443-0.

[22] A. Lukezic, T. Vojir, L. Cehovin, J. Matas y M. Kristan, «Discriminative Correlation Filter with Channel and Spatial Reliability,» en *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, págs. 4847-4856. DOI: 10.1109/CVPR.2017.515.

[23] J. F. Henriques, R. Caseiro, P. Martins y J. Batista, «High-Speed Tracking with Kernelized Correlation Filters,» *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 37, n.º 3, págs. 583-596, 2015. DOI: 10.1109/TPAMI.2014.2345390.

[24] Y. LeCun, L. Bottou, Y. Bengio y P. Haffner, «Gradient-based learning applied to document recognition,» *Proceedings of the IEEE*, vol. 86, n.º 11, págs. 2278-2324, 1998. DOI: 10.1109/5.726791.

[25] S. J. Pan y Q. Yang, «A survey on transfer learning,» *IEEE Transactions on Knowledge and Data Engineering*, vol. 22, n.º 10, págs. 1345-1359, 2010. DOI: 10.1109/TKDE.2009.191.

[26] K. He, X. Zhang, S. Ren y J. Sun, «Deep Residual Learning for Image Recognition,» en *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, págs. 770-778. DOI: 10.1109/CVPR.2016.90.

[27] D. P. Kingma y J. Ba, «Adam: A Method for Stochastic Optimization,» en *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015. dirección: https://arxiv.org/abs/1412.6980.

[28] R. S. Pressman y B. R. Maxim, *Software Engineering: A Practitioner's Approach*, 8.ª ed. McGraw-Hill Education, 2014.

[29] I. Sommerville, *Software Engineering*, 10.ª ed. Pearson, 2016.

[30] G. Bradski y A. Kaehler, *Learning OpenCV: Computer Vision with the OpenCV Library*. O'Reilly Media, 2008.

[31] M. Abadi, P. Barham, J. Chen et al., «TensorFlow: A System for Large-Scale Machine Learning,» en *Proceedings of the 12th USENIX Symposium on Operating Systems Design and Implementation (OSDI)*, 2016, págs. 265-283. dirección: `https://www.usenix.org/conference/osdi16/technical-sessions/presentation/abadi`.

[32] F. Pedregosa, G. Varoquaux, A. Gramfort et al., «Scikit-learn: Machine Learning in Python,» *Journal of Machine Learning Research*, vol. 12, págs. 2825-2830, 2011.

[33] M. Grinberg, *Flask Web Development: Developing Web Applications with Python*, 2.ª ed. O'Reilly Media, 2018.

[34] D. Merkel, «Docker: Lightweight Linux Containers for Consistent Development and Deployment,» *Linux Journal*, vol. 2014, n.º 239, pág. 2, 2014.

[35] O. Friard y M. Gamba, «BORIS: a free, versatile open-source event-logging software for video/audio coding and live observations,» *Methods in Ecology and Evolution*, vol. 7, n.º 11, págs. 1325-1330, 2016. DOI: `10.1111/2041-210X.12584`.